

ChewML

Essklassifikation aus AirPods-Pro-Bewegungsdaten

Still

Apfel

Kaugummi

Skyr

Live-Erkennung über ein hierarchisches 2-Stufen-Modell · LOSO-validiert

Recap & Motivation

- 1 In den AirPods Pro steckt eine IMU — Beschleunigungs- und Drehratensensor, ~50 Hz.
- 2 Beim Kauen überträgt sich die Kieferbewegung über den Schädel auf den Kopfhörer.
- 3 Hypothese: verschiedene Speisen erzeugen verschiedene Bewegungs-Signaturen.
- 4 Anwendung: automatisches Ernährungstagebuch, ohne Foto, ohne Tippen.

Bewegungs-Signaturen

Apfel

impulsiv, knackig

Kaugummi

gleichmäßig, zäh

Skyr

weich, rhythmisch


Idee: Proof of Concept für passives Ernährungs-Tracking allein über AirPods-Bewegungsdaten ohne Zusatzhardware.

Verwandte Arbeiten

EarBit (UbiComp 2018)

PMC · [ncbi.nlm.nih.gov](https://pubmed.ncbi.nlm.nih.gov/)

Tragbare In-Ear-Sensoren zur Erkennung von Essepisoden in unkontrollierten Umgebungen. Zeigt, dass passiv getragene Ohrsensoren Essen zuverlässig erkennen können.




Verwandte Arbeiten

CHOMP (arXiv 2026)

Multimodal earphone study

IMU + Mikrofon + PPG, 11 Lebensmittel, 20 Probanden. 97,7 % leave-one-food-out Genauigkeit. Erkennung ungesunder Kaumuster.


A. OpenEareable 2.0




B. Monitor Chewing



C. Detect Chewing Side



D. Chewing Side Analysis



Verwandte Arbeit

Papapanagiotou et al. (2021) — arXiv:2105.09621

Recognition of food-texture attributes using an in-ear microphone.

- In-Ear-Mikrofon (Prototyp-Hardware, EU-Projekt SPLENDID)
- Ziel: 3 Textur-Attribute erkennen — Knusprigkeit, Feuchtigkeit, Zähigkeit
- Methode: 3 binäre SVMs mit RBF-Kernel (je eines pro Attribut)
- Validierung: LOSO · 9 Personen · 9 Speisen · 4.989 Kau-Bewegungen
- Ergebnis: Knusprigkeit 95 % · Feuchtigkeit 80 % · Zähigkeit 63 %

	Crispy	Wet	Chewy
apple	✓	✓	✗
banana	✗	✓	✗
bread	✗	✗	✗
candy bar	✗	✗	✓
cookie	✓	✗	✗
lettuce	✓	✓	✗
potato chips	✓	✗	✗
strawberry	✗	✓	✗
toffee	✗	✗	✓

Gleiche Idee, anderer Kanal: Audio → IMU · Textur-Attribut → konkrete Speise

Der Weg bisher



Heute der konsolidierte Endstand: Alle Zahlen LOSO-validiert, plus Live-Demo.

Feature Engineering — 52 Merkmale je 10-s-Fenster

aus 9 Rohsignalen (3 Beschleunigung · 3 Drehrate · 3 Orientierung), gruppiert nach physikalischer Bedeutung

Bewegungsstärke & Statistik *14 Merkmale*

magnitude_std · lin_z_std · stillness_ratio · movement_events

Stärke der Kopfbewegung: Mittelwert, Streuung und Maximum

Rotation & Orientierung *18 Merkmale*

rotationRateX_std · pitch_range · yaw_std · roll_mean

Drehung und Haltung des Kopfes beim Kauen

Kau-Rhythmus *6 Merkmale*

chews_per_sec · ac_peak_height · rhythmicity · inter_chew_cv

Wie schnell und wie regelmäßig gekaut wird

Frequenzspektrum *9 Merkmale*

band_power_fast · spectral_entropy · high_freq_power · dominant_chew_freq

Verteilung der Bewegungsenergie über die Frequenzen

Impuls & Signalform *5 Merkmale*


jerk_mean · jerk_std · crest_factor · mag_kurtosis

Wie ruckartig das Signal ist — kurze, harte Ausschläge

Daten & Setup


- 90 Aufnahmen, je ~2–3 Minuten, mit AirPods Pro + iPhone (Sensor Logger, ~50 Hz).
- Aufgeteilt in 1270 Zehn-Sekunden-Fenster über fünf Kategorien (Still, Apfel, Kaugummi, Skyr, generisches Essen).
- Viele getrennte Sessions pro Klasse zu unterschiedlichen Zeiten, mal links, mal rechts getragen.

Datensatz: AirPods-Pro-IMU, 50 Hz, je ~2-3 Min/Aufnahme



Grundlage für session-übergreifendes (LOSO) Testen.

HTTP-Streaming & Sliding Windows



Mehrheitsentscheid ueber alle Fenster → ein Label pro Mahlzeit

Modellauswahl — warum zwei Stufen?

Das Problem zerfällt in zwei sehr unterschiedliche Fragen:

Frage 1

Isst die Person überhaupt?

Stufe 1 · Random Forest

Still vs. Essen



Frage 2

Welche Speise genau?

Stufe 2 · SVM (RBF)


Apfel / Kaugummi / Skyr

- Beide Fragen in einem Modell zu lösen verschlechterte in Tests die Speise-Erkennung. Generisches „Essen“ verwässert die feinen Speise-Klassen.
- Hierarchisch getrennt bekommt jede Stufe ihre eigenen, optimal passenden Merkmale.
- Andere Algorithmen (kNN, MLP) wurden in der Exploration ebenfalls getestet und lagen nah an RF/SVM


Modellvergleich

Modellvergleich (LOSO) — identische Features, getrennt je Stufe

Stufe 1 — Still vs. Essen




Stufe 2 — Apfel / Kaugummi / Skyr



Feature Selection — Stufe 1 (Still vs. Essen)

- Mehr Features bringen offline kaum etwas: Deploy (14), ohne Rotation/Orientierung (34) und alle 52 liegen nur ~1,5 Pp auseinander
- Volle Features schaden aber live, weil Orientierungs- und Rotationsmerkmale bei Sprechen und Kopfbewegung Fehlalarme auslösen
- Deshalb 14 kompakte Rhythmus-Features: bewusst für Live-Robustheit gewählt, offline fast ohne Kosten



Ergebnis (Still vs. Essen) — Stufe 1



93,7 %

Accuracy (LOSO)

Essen-F1 96 % — sehr zuverlässig: wenn wirklich gegessen wird, merkt die App es.

Still-F1 89 % — die wenigen Fehler sind Grenzfälle wie Sprechen oder Schlucken.

Stufe 1 — Still vs. Essen (Random Forest, LOSO-Validierung)




Bewusste Asymmetrie: lieber Essen sicher erkennen als jede Kopfbewegung ignorieren.


Feature Selection — Stufe 2 (Feinklassifikation)

- Auswahl per group-aware Permutation Importance: gemessen wird, wie viel ein Merkmal sessionübergreifend wirklich bringt, statt nur auf den Trainingssessions zu glänzen
- Ergebnis: 48 von 52 Merkmalen bleiben, nur 4 fliegen raus (movement_events, roll_std, lin_x_mean, roll_range), also redundante Bewegungszählung und absolute Kopfneigung als reines Session-Rauschen
- Dass fast alles bleibt, zeigt: die 52 Features tragen breit zur Trennung bei; am stärksten jerk_mean, jerk_std und rotationRateX_std

Stufe 2 - Top 8 Merkmale




Stufe 2 - Schlechteste 8 Merkmale (4 fliegen raus)



Deep Learning vs. Feature Engineering

- Naheliegende Frage: braucht es handgemachte Features, oder lernt ein 1D-CNN direkt auf dem Rohsignal alles selbst?
- Getestet mit Daten-Augmentierung (Zeitverschiebung, Rauschen, Skalierung).
- Ergebnis: das CNN kommt nur gleichauf (85 %) —> kein Vorteil trotz deutlich mehr Rechenaufwand und schlechterer Interpretierbarkeit.
- Für den kleinen Datensatz und die Live-Anwendung sind erklärbare Features die bessere Wahl.



Hinweise: Es wurde mit K-Fold und nicht LOSO getestet, weshalb die Accuracy niedriger ist.

Ergebnis (Apfel / Kaugummi / Skyr) — Stufe 2


90,4 %

Accuracy (LOSO)

Stufe 2 — Feinklassifikation Apfel/Kaugummi/Skyr (SVM RBF, LOSO)

Konfusionsmatrix (Acc 90.4 %)

Wahr \ Vorhergesagt	Apfel	Kaugummi	Skyr
Apfel	186 91%	14 7%	5 2%
Kaugummi	16 10%	133 82%	14 9%
Skyr	17 5%	2 1%	324 94%



End-to-End & Mehrheitsentscheid

Pro Fenster

87,3 %

ein einzelnes 10-s-Fenster

Pro Mahlzeit

97,7 %

Mehrheitsentscheid über alle Fenster

End-to-End (Stufe 1 + Stufe 2, LOSO) — der Mehrheitsentscheid rettet Fensterfehler

Pro Fenster (Acc 87.3 %)					
Wahr	Still	333 94%	3 1%	4 1%	16 4%
	Apfel	6 3%	182 89%	13 6%	4 2%
	Kaugummi	9 6%	12 7%	128 79%	14 9%
	Skyr	43 13%	10 3%	2 1%	288 84%
		Still	Apfel	Kaugummi	Skyr
		Vorhergesagt			

Pro Mahlzeit (Acc 97.7 %)					
Wahr	Still	Apfel	Kaugummi	Skyr	
	19 100%	0 0%	0 0%	0 0%	
	0 0%	22 100%	0 0%	0 0%	
	0 0%	1 5%	19 95%	0 0%	
Skyr	1 4%	0 0%	0 0%	24 96%	
		Still	Apfel	Kaugummi	Skyr
		Vorhergesagt			

Finaler Stand der Daten (LOSO-Validierung)

Stufe	Klasse	Precision	Recall	F1	Support
STUFE 1	Still	90 %	87 %	89 %	356
	Essen	95 %	96 %	96 %	914
STUFE 2	Apfel	85 %	91 %	88 %	205
	Kaugummi	89 %	82 %	85 %	163
	Skyr	94 %	94 %	94 %	343

End-to-End: 87 % pro Fenster -> 98 % pro Mahlzeit | 1270 Fenster, 90 Sessions

Diese Zahlen sind komplett gemessen auf ungesehenen Aufnahmen (LOSO).

Live-Demo

AirPods anlegen · Web-App zeigt das Live-Ergebnis

Live-Status: Fenster wird klassifiziert ...

Still

Apfel

Kaugummi

Skyr

Mahlzeit-Votum: wird über alle Fenster der laufenden Mahlzeit gesammelt →

→ Mahlzeit erkannt: APFEL

Ablauf: Start mit Stille (App bleibt auf Still) → Apfel essen → Stimmen sammeln sich → Mahlzeit als Apfel gewertet.

Plan B bei WLAN-Problemen: vorbereitetes Demo-Video

Grenzen & Lessons Learned

Kaugummi ↔ Apfel

Schwierigstes Paar: ähnlicher Kaurhythmus und weniger Daten.

Sprechen als Essen

Wird häufig als Essen klassifiziert; mehr Sprech-Daten nötig.

Eine Person

Alles auf eine Person trainiert: Generalisierung auf fremde Nutzer nicht getestet.

Wichtigste Lektion

Nicht der Algorithmus war entscheidend, sondern ehrliche Validierung (LOSO) und gute Features.

Mögliches Vorgehen

- 1 Mehr Personen für nutzerübergreifende Generalisierung.
- 2 Mehr Sprech-/Schluck-Aufnahmen, um die Fehlalarme zu verringern.
- 3 Mehr Speisen-Klassen.
- 4 On-Device-Modell direkt auf dem iPhone ohne HTTP-Streaming.

Danke.

ChewML erkennt aus AirPods-Bewegungsdaten zuverlässig, ob und was gegessen wird.

97,7 % pro Mahlzeit · session-übergreifend validiert · live lauffähig

Fragen & Diskussion

Quellen

Bedri, A., Li, R., Haynes, M., Kosaraju, R. P., Grover, I., Prioleau, T., Beh, M. Y., Goel, M., Starner, T., & Abowd, G. (2017). EarBit: Using wearable sensors to detect eating episodes in unconstrained environments. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 1(3), Article 37.

<https://doi.org/10.1145/3130902>

Bell, B. M., Alam, R., Alshurafa, N., Thomaz, E., Mondol, A. S., de la Haye, K., Stankovic, J. A., Lach, J., & Spruijt-Metz, D. (2020). Automatic, wearable-based, in-field eating detection approaches for public health research: a scoping review. *npj Digital Medicine*, 3(1), Article 38.

<https://doi.org/10.1038/s41746-020-0246-2>

Hummel, J., Burzer, M., Schlotter, F., Kuttner, M., King, T., Yang, Q., Mascolo, C., Beigl, M., & Roddiger, T. (2026). CHOMP: Multimodal chewing side detection with earphones. *arXiv*.

<https://arxiv.org/abs/2602.02233>

Ketmalasiri, T., Wu, Y. Y., Butkow, K.-J., Mascolo, C., & Liu, Y. (2024). IMChew: Chewing analysis using earphone inertial measurement units. In *BodySys '24: Proceedings of the Workshop on Body-Centric Computing Systems* (pp. 29-34). ACM.

<https://doi.org/10.1145/3662009.3662022>

Papapanagiotou, V., Diou, C., van den Boer, J., Mars, M., & Delopoulos, A. (2021). Recognition of food-texture attributes using an in-ear microphone. arXiv preprint arXiv:2105.09621.

<https://arxiv.org/abs/2105.09621>