

ChewML: Klassifikation von Lebensmitteln anhand von Kaubewegungen aus AirPods-IMU-Daten

Jonah Karstens (4004353)
jonah.karstens@stud.leuphana.de

Seminar „Machine Learning for Smart and Connected Systems“ (ML4SCS)
Modul 45005000 Vertiefungsmodul • Sommersemester 2026
Prof. Dr. Burkhardt Funk, Maximilian Hannes Reinhardt
Leuphana Universität Lüneburg

15. September 2026

Kurzfassung

Diese Arbeit untersucht, ob sich Lebensmittel anhand der Kaubewegung klassifizieren lassen, die von den Inertialsensoren handelsüblicher AirPods Pro erfasst wird. Über die iOS-App Sensor Logger wurden bei etwa 50 Hz insgesamt 103 Aufnahmen einer einzelnen Versuchsperson aufgezeichnet, verteilt auf die Klassen Apfel, Kaugummi, Skyr, Stillsitzen sowie eine generische Klasse für sonstiges Essen. Aus nicht überlappenden Zehn-Sekunden-Fenstern wurden 52 Merkmale aus Zeit- und Frequenzbereich extrahiert, darunter eigens entwickelte Kaudynamik-Merkmale zu Impulsivität, Rhythmusregularität und Kaufrequenz. Als Architektur dient ein hierarchischer Zwei-Stufen-Klassifikator: Ein Random Forest trennt Stillsitzen von Essen, eine Support Vector Machine klassifiziert anschließend das konkrete Lebensmittel. Ein methodischer Schwerpunkt liegt auf einer ehrlichen Evaluation. Während die Genauigkeit innerhalb einzelner Aufnahmen 93,8 % beträgt, liegt sie über Aufnahmen hinweg bei 88,7 %; durch Mehrheitsabstimmung über alle Fenster einer Mahlzeit steigt sie auf 95,0 %. Ein Vergleich mit einem 1D-CNN auf Rohdaten zeigt, dass Deep Learning bei dieser Datenmenge keinen Vorteil bringt. Eine Live-Webanwendung demonstriert die Machbarkeit im Echtzeitbetrieb. Die zentrale Limitation ist die Beschränkung auf eine Versuchsperson, weshalb die Übertragbarkeit auf andere Personen offen bleibt.

Keywords: *Human Activity Recognition; Earable Computing; Inertialsensorik; Ernährungstracking; Support Vector Machine.*

1 Einleitung

Ein Ernährungstagebuch, das man einfach im Ohr trägt: Diese Idee bildet den Ausgangspunkt der vorliegenden Arbeit. Die meisten heutigen Ansätze zum Ernährungstracking beruhen auf manueller Eingabe in Apps oder auf dem Fotografieren von Mahlzeiten. Beide sind aufwendig, fehleranfällig und werden im Alltag häufig nicht durchgehalten. Untersucht wird deshalb eine passive Alternative, nämlich die Nutzung der Bewegungssensoren, die in AirPods Pro ohnehin verbaut sind. Beim Kauen unterschiedlicher Lebensmittel entstehen charakteristische Kieferbewegungen, die sich als Muster in den Beschleunigungs-, Gyroskop- und Orientierungsdaten der im Ohr sitzenden Sensoren niederschlagen.

Die Erkennung von Kau- und Essaktivität lässt sich dem Forschungsfeld der Human Activity Recognition zuordnen (Bulling et al., 2014, S. 33:1), genauer dem noch jungen Teilgebiet des „Earable Computing“, das Sensorik in Ohrhörern für die

Aktivitätserkennung nutzt. Arbeiten wie EarBit (Bedri et al., 2017) haben gezeigt, dass Essenserkennung über Sensoren am Ohr grundsätzlich möglich ist, allerdings meist mit spezialisierter Forschungshardware und mehreren Sensormodalitäten. Der Reiz dieses Projekts liegt darin, ausschließlich die IMU-Daten eines millionenfach verbreiteten Consumer-Geräts zu verwenden, ohne zusätzliche Hardware, Mikrofone oder Kameras.

Die zentrale Forschungsfrage lautet: Können Kaubewegungen, die über die In-Ear-IMU-Sensoren von AirPods Pro erfasst werden, genutzt werden, um verschiedene Lebensmittel zu klassifizieren und Essen von Nicht-Essen zu unterscheiden? Zur Beantwortung wurden vier Kernklassen definiert, die bewusst unterschiedliche Kaucharakteristiken abdecken: Apfel (hart, knackig, impulsive Kaubewegungen), Kaugummi (gummiartig, schnelle gleichmäßige Zyklen), Skyr (weich, löffelbar, langsame rhythmische Bewegung) und Stillsitzen. Im Projektverlauf kam eine generische Klasse „Essen“ hinzu, die beliebige weitere Lebensmittel repräsentiert. Neben der Klassifikation selbst war ein zweites Ziel die Umsetzung eines lauffähigen Gesamtsystems, das den Sensordatenstrom in Echtzeit entgegennimmt und Mahlzeiten automatisch erkennt.

Das Projekt wurde als Einzelarbeit durchgeführt, beginnend erst in der fünften Semesterwoche nach einem Gruppenwechsel, sodass Projektdefinition, Datenerhebung und Pipeline in der verbleibenden Zeit von einer Person aufgebaut wurden.

2 Verwandte Arbeiten

Zur Einordnung wurden fünf Arbeiten analysiert: ein Scoping Review als Überblick sowie drei Arbeiten zur ohrbasierten Ess- und Kauerkennung und eine Arbeit zur Texturerkennung über ein In-Ear-Mikrofon.

Einen systematischen Überblick liefert das Scoping Review von Bell et al. (2020), das 40 Feldstudien aus 33 Artikeln auswertet. Als Motivation nennen die Autoren die Schwächen der klassischen Ernährungserhebung, die auf Selbstauskunft beruht und mit Erinnerungsverzerrungen behaftet ist, während tragbare Sensoren Essaktivität passiv erfassen (Bell et al., 2020, S. 1). Drei Befunde sind hier relevant. Bewegungssensoren dominieren das Feld: Ein Beschleunigungssensor kommt in 25 der 40 Studien zum Einsatz, ein Gyroskop in 15 und ein Mikrofon in acht, wobei die Bewegungssensoren meist am Handgelenk sitzen; eine Inertialmesseinheit am Ohr taucht in genau einer Studie auf (Bell et al., 2020, S. 9–10). Die erfassten Zielgrößen sind Essgelegenheiten (37 Studien), Kauanzahl (drei) und Hand-zu-Mund-Bewegungen (zwei); das konkrete Lebensmittel gehört nicht dazu (Bell et al., 2020, S. 10). Schließlich lassen zwei Studien das Gerät bei erkannter Essbewegung direkt beim Nutzer nachfragen, ein Vorgehen, dessen weitere Erprobung die Autoren empfehlen (Bell et al., 2020, S. 9 und S. 11).

Die Studie EarBit (Bedri et al., 2017) untersucht die Erkennung von Essepisoden mit am Kopf getragenen Sensoren und nutzt Kauen als Stellvertreter für Essen. Verglichen wurden optische, inertielle und akustische Sensorik; als beste Variante erwies sich ein Inertialsensor hinter dem Ohr, ergänzt um einen zweiten im Nacken, der grobe Körperbewegungen

herausfiltert (Bedri et al., 2017, S. 3 und S. 11). Im unkontrollierten Alltagseinsatz mit zehn Teilnehmenden und 45 Stunden Aufzeichnung erkannte EarBit Kauen im Sekundentakt mit einer Genauigkeit von 93 % bei einem F1-Wert von 80,1 %; zu Essepisoden aggregiert wurden 15 von 16 Mahlzeiten erkannt (Bedri et al., 2017, S. 3 und S. 16).

Der Fragestellung dieser Arbeit am nächsten kommt die Studie von Papapanagiotou et al. (2021), die aus dem Kaugeräusch eines In-Ear-Mikrofons auf Eigenschaften des Lebensmittels selbst schließt. Erkannt werden drei sensorische Texturattribute, nämlich Knusprigkeit, Feuchtigkeit und Zähigkeit, jeweils über eine eigene binäre Support Vector Machine (Papapanagiotou et al., 2021, S. 1 und S. 3). Der Datensatz umfasst neun Probanden und neun Lebensmittel. Die Knusprigkeit erweist sich mit einer gewichteten Genauigkeit von mindestens 0,90 als zuverlässigstes Attribut (Papapanagiotou et al., 2021, S. 10), während Feuchtigkeit und Zähigkeit deutlich schlechter abschneiden (Papapanagiotou et al., 2021, S. 8).

IMChew (Ketmalasiri et al., 2024) untersucht, wie sich Kauaktivität und Kauanzahl allein aus den Inertialsensoren von Ohrhörern bestimmen lassen, und grenzt mikrofonbasierte Systeme bewusst ab, da diese im Alltag als aufdringlich gelten, während Inertialsensoren in handelsüblichen Ohrhörern bereits serienmäßig verbaut sind (Ketmalasiri et al., 2024, S. 29). Erhoben wurden Daten von acht Probanden mit der Forschungsplattform eSense bei 60 Hz (Ketmalasiri et al., 2024, S. 31). Aus Drei-Sekunden-Fenstern werden 96 Merkmale extrahiert (Ketmalasiri et al., 2024, S. 30–31); unter Leave-One-Subject-Out erreicht ein Random Forest pro Fenster 0,86, aggregiert auf Zehn-Sekunden-Episoden 0,91 (Ketmalasiri et al., 2024, S. 32).

Die jüngste Arbeit, CHOMP (Hummel et al., 2026), stellt das erste System zur Erkennung der Kauseite mit Ohrhörern vor; die Motivation ist medizinisch, da eine einseitige Kaupräferenz als Risikofaktor für kranio-mandibuläre Dysfunktionen gilt (Hummel et al., 2026, S. 1). Zum Einsatz kommen zwei Geräte der Plattform OpenEarable 2.0 mit fünf Sensormodalitäten. Die stärkste Einzelmodalität sind die Mikrofone mit einem medianen F1-Wert von 94,5 % unter Leave-One-Food-Out und 92,6 % unter Leave-One-Subject-Out; die IMU liegt mit 84,8 beziehungsweise 84,5 % im Mittel um 8,9 Prozentpunkte darunter (Hummel et al., 2026, S. 17).

Aus diesen Arbeiten ergibt sich eine Forschungslücke. Die Machbarkeit der Essenserkennung am Ohr ist belegt, wobei sich bei EarBit gerade ein Inertialsensor gegenüber optischer und akustischer Sensorik durchsetzte (Bedri et al., 2017, S. 3). Der Kaurhythmus ist charakterisiert: IMChew sucht die dominante Kaufrequenz zwischen 0,5 und 2,5 Hz (Ketmalasiri et al., 2024, S. 31), CHOMP filtert die IMU-Kanäle mit einem Bandpass von 0,1 bis 6,0 Hz und begründet dies damit, dass der Kaurhythmus typischerweise unter 3 Hz liegt (Hummel et al., 2026, S. 10). Und feingranulare Eigenschaften des Kauens sind erkennbar, da CHOMP die Kauseite allein aus IMU-Daten mit einem medianen F1-Wert von 84,5 % über unbekannte Probanden unterscheidet (Hummel et al., 2026, S. 17). Das konkrete Lebensmittel ist dagegen in keiner der betrachteten Arbeiten Zielgröße; unter 40 ausgewerteten Feldstudien nutzt genau eine

eine ohrgetragene IMU, und keine erfasst das Lebensmittel (Bell et al., 2020, S. 9–10). Hinzu kommt, dass sämtliche betrachteten Systeme auf Forschungshardware beruhen. IMChew nennt die AirPods zwar ausdrücklich als Beispiel für Ohrhörer mit serienmäßiger IMU (Ketmalasiri et al., 2024, S. 29), erhebt seine Daten aber nicht damit.

An diese Arbeiten knüpft das Projekt in drei Punkten an, die dort nicht vorkommen: die Unterscheidung dreier bewusst sehr unterschiedlicher Lebensmittel anhand ihrer Kaubewegung, die Verwendung eines unveränderten Massenmarktprodukts statt Forschungshardware und die Umsetzung als Echtzeitsystem bis zur Erkennung einer Mahlzeit. Zwei Entscheidungen sind aus der Literatur übernommen: der Frequenzbereich der Kaumerkmale, hier mit 0,5 bis 4 Hz an der Obergrenze etwas weiter gefasst, sowie die Validierung nach dem Prinzip des Leave-One-Subject-Out, das hier mangels weiterer Probanden auf Aufnahmen statt Probanden angewandt wird. Die Abkürzung LOSO steht im Folgenden daher für Leave-One-Session-Out.

3 Daten und Methodik

3.1 Datenerhebung

Für die Datenerhebung wurden AirPods Pro in Verbindung mit der iOS-App Sensor Logger verwendet, die die Motion-Daten über das iPhone ausliest und als CSV-Dateien exportiert. Aufgezeichnet wurden mit einer Abtastrate von etwa 50 Hz die Beschleunigung der Ohrhörer, der Gravitationsvektor, die Rotationsraten des Gyroskops sowie die Euler-Winkel. Jede Aufnahme enthält genau eine Aktivität; die Zuordnung zur Klasse erfolgt über eine Namenskonvention, sodass neue Aufnahmen ohne Codeänderung ergänzt werden können.

Die Erhebung erfolgte iterativ über den gesamten Projektzeitraum, beginnend mit einem Minimaldatensatz von zwölf Aufnahmen und wachsend über 24, 72, 78 und 89 auf final 103 Aufnahmen: 27 Apfel, 28 Kaugummi, 25 Skyr, 19 Still sowie vier Aufnahmen der generischen Klasse (reale Mahlzeiten wie Chili con Carne oder Overnight Oats). Die letzte Erhebungsrunde diente gezielt dem Klassenausgleich, bis alle drei Speiseklassen mit 308, 312 und 343 Zeitfenstern annähernd gleich stark vertreten waren. Die Aufnahmen entstanden über mehrere Monate zu unterschiedlichen Tageszeiten, wobei die AirPods vor jeder Aufnahme neu eingesetzt wurden, sodass sich Sitzposition und Sensorlage zwischen den Aufnahmen unterscheiden. Abbildung 1 zeigt die Verteilung.




Abbildung 1: Finaler Datensatz: 103 Aufnahmen einer Versuchsperson, Verteilung pro Klasse.

Bereits die visuelle Inspektion der Rohsignale zeigt deutliche Klassenunterschiede (Abbildung 2): Stillsitzen erzeugt ein nahezu flaches Magnitudensignal mit sehr geringer Varianz, während alle Essklassen rhythmische Oszillationen mit klassenspezifischer Amplitude und Frequenz aufweisen.




Abbildung 2: Magnitudensignal über die Zeit für eine repräsentative Aufnahme pro Klasse.

Zwei Erkenntnisse prägten den weiteren Verlauf. Erstens erwies sich die Datenqualität als kritischer Faktor, da einzelne Aufnahmen mehrsekündige Kopfbewegungsphasen enthalten, die physikalisch nichts mit dem Essen zu tun haben, aber die Merkmalsstatistiken verfälschen. Zweitens stammen sämtliche Aufnahmen von einer einzigen Versuchsperson; die geplante Erhebung weiterer Probanden ließ sich im Projektzeitraum nicht realisieren, und eine Suche nach öffentlich verfügbaren Datensätzen mit vergleichbaren Kauaufnahmen blieb erfolglos.

3.2 Vorverarbeitung

Von jeder Aufnahme wurden die ersten und letzten zwei Sekunden entfernt, um Artefakte beim Starten und Stoppen auszuschließen. Auf eine Subtraktion des Gravitationsanteils wurde bewusst verzichtet, da die beiden Größen in unterschiedlichen Einheiten vorliegen: Die Beschleunigungsachsen werden in Vielfachen der Erdbeschleunigung ausgegeben, der Gravitationsvektor dagegen in m/s^2 (Choi, o.J.). Hinzu kommt, dass die

Beschleunigungswerte aus der Sensorfusion des Betriebssystems stammen und die Erdbeschleunigung bereits nicht mehr enthalten; ihr Betrag liegt im Median deutlich unter 0,1 g, während der Gravitationsvektor durchgehend den Betrag $9,807 \text{ m/s}^2$ aufweist. Ein früher Versuch, ihn dennoch abzuziehen, bestätigte das: Die Magnitude lag anschließend für jede Klasse bei etwa 9,81, die Signale wurden flach und die Genauigkeit fiel auf rund 70 %. Aus den unverändert übernommenen Achsen wurde ein skalares Magnitudensignal gebildet, das die Gesamtintensität der Kopf- und Kieferbewegung unabhängig von der Sensororientierung erfasst und die Grundlage der meisten frequenzbasierten Merkmale bildet.

Zwei klassische Filteransätze wurden untersucht. Ein Butterworth-Tiefpassfilter vierter Ordnung, dessen kennzeichnende Eigenschaft ein im Durchlassbereich gleichmäßiger Frequenzgang ist (Butterworth, 1930, S. 536), wurde nullphasig mit Grenzfrequenzen von 1, 2, 4 und 6 Hz angewendet. Für sich genommen hilft er deutlich, da die Genauigkeit von 85,0 % ohne Filterung auf 93,3 % bei 4 Hz steigt. In Kombination mit der unten beschriebenen Movement-Segment-Exclusion kehrt sich das Bild jedoch um: Diese erreicht allein 98,3 %, zusammen mit dem Tiefpass nur noch 91,7 %. Beide Schritte setzen an derselben Störung an, und die Glättung verschlechtert die Grundlage, auf der die Movement Exclusion ihren Schwellwert bildet. In der finalen Pipeline wird daher kein Tiefpass eingesetzt. Ein Hampel-Filter, der jeden Messwert mit dem gleitenden Median seiner Umgebung vergleicht und ihn ersetzt, wenn er weiter als ein Vielfaches der über die mediane absolute Abweichung geschätzten Streuung entfernt liegt (Pearson et al., 2016, S. 2), entfernte bei 3σ fälschlich echte Kauspitzen und ließ die Genauigkeit bei 5σ unverändert. Beide Experimente führten zum selben Schluss: Weder hochfrequentes Rauschen noch isolierte Ausreißer verursachen die Fehlklassifikationen, sondern anhaltende Kopfbewegungsphasen.

Daraus entstand ein eigener Ansatz, der zusammenhängende Bewegungsphasen ausschließt statt einzelner Datenpunkte. Für jedes auszuwertende Zeitfenster wird ein adaptiver Schwellwert als $\max(0,02 \text{ g}, 5 \times \text{Median der Fenster-Magnitude})$ berechnet. Er skaliert damit automatisch mit dem Grundrauschen des Fensters, ohne Klassenlabels zu benötigen, und liefert Werte, die der Domänenintuition entsprechen (typisch je Klasse: Still 0,020 g, Skyr 0,060 g, Apfel 0,095 g). Ein gleitendes Maximum über eine Sekunde sorgt dafür, dass ganze kontaminierte Abschnitte entfernt werden (Abbildung 3). Auf dem damaligen Datensatz von 24 Aufnahmen hob dieser Schritt die Genauigkeit von 87,5 % auf 100 % und war der bis dahin größte Einzeleffekt. Später zeigte die Fehleranalyse jedoch, dass er auch die impulsiven Crunch-Spitzen des Apfels entfernt, also genau jene Signalanteile, die den harten Apfel von weichem Essen unterscheiden. Die finale Architektur verwendet ihn daher hybrid: Stufe 1 nutzt ihn immer, Stufe 2 arbeitet ohne ihn.




Abbildung 3: Movement-Segment-Exclusion mit adaptivem Schwellwert (gestrichelt) für je eine Aufnahme pro Klasse. Rot schattierte Bereiche werden ausgeschlossen. Die Grafik stammt aus der frühen Analysephase mit sessionweisem Median; die finale Pipeline bildet den Median pro Zehn-Sekunden-Fenster.

Die Aufnahmen wurden in nicht überlappende Zeitfenster von einheitlich zehn Sekunden unterteilt, sodass Offline-Evaluation und Echtzeitbetrieb dieselbe Segmentierung verwenden. Kürzere Fenster kosten etwas Genauigkeit, sind für den Livebetrieb aber nötig, weil die Fensterlänge unmittelbar bestimmt, wie lange ein Erkennungssystem auf sein erstes Ergebnis warten muss (Bulling et al., 2014, S. 33:10). Ein Experiment mit überlappenden Fenstern zeigte das Gegenteil des Erhofften: Je stärker die Überlappung, desto schlechter die sessionübergreifende Genauigkeit, die trotz einer auf 2409 aufgeblähten Fensteranzahl von 76 % auf etwa 71 % fiel. Überlappende Fenster derselben Aufnahme sind stark korreliert und erhöhen die scheinbare Datenmenge, ohne neue Information beizutragen.

3.3 Merkmale und Merkmalsauswahl

Pro Zeitfenster wurden zunächst 36 Basismerkmale aus drei Domänen extrahiert: aus dem Zeitbereich Mittelwert, Standardabweichung und Maximum der Beschleunigungsachsen, der Magnitude und der Gyroskopachsen sowie der Anteil sehr ruhiger Datenpunkte und die Anzahl der Bewegungsereignisse; aus den Euler-Winkeln Mittelwert, Standardabweichung und Wertebereich; aus dem Frequenzbereich auf Basis der

Welch-Leistungsspektraldichte die dominante Kaufrequenz im Band von 0,5 bis 4 Hz, die Bandleistung, die Gesamtleistung sowie deren Verhältnis als Maß der Rhythmizität.

Da diese statistischen Merkmale die feinen Unterschiede zwischen den Esstexturen nur unvollständig erfassten, wurden 16 weitere Merkmale entworfen, jeweils ausgehend von einer physikalischen Annahme. Die erste betrifft den Apfel: Ein harter Biss sollte kurze, kräftige Impulse auf ruhigem Grund erzeugen. Umgesetzt wurde das über Wölbung und Schiefe der Amplitudenverteilung, den Crest-Faktor sowie den Jerk, also die zeitliche Ableitung der Beschleunigung. Bestätigt hat sich davon vor allem der Jerk, dessen Mittelwert im finalen Modell mit deutlichem Abstand das wichtigste Merkmal ist und dessen Streuung auf Rang vier folgt, während von den Formmaßen nur die Wölbung erhalten bleibt. Die zweite Annahme betrifft das Kaugummi, bei dem derselbe Bewegungsablauf wiederholt wird und das Signal daher ausgeprägt periodisch sein sollte. Umgesetzt wurde das über die Autokorrelation, deren höchstes Nebenmaximum im Kauband die Wiederholgenauigkeit angibt, sowie über die Anzahl erkannter Kauspitzen pro Sekunde und die Streuung ihrer Abstände. Diese Annahme hat sich bestätigt, da alle vier rhythmusbezogenen Merkmale erhalten bleiben und zwei davon unter den ersten zehn stehen. Der Merkmalsatz umfasst damit 52 Werte pro Zeitfenster.

Die Merkmalsselektion erwies sich als eines der schwierigsten Teilprobleme und wurde für beide Stufen getrennt durchgeführt. Für Stufe 1 wählte eine rekursive Merkmalseliminierung, die wiederholt ein Modell trainiert und jeweils das schwächste Merkmal entfernt (Guyon et al., 2002, S. 394), in einem frühen Versuch nur fünf Merkmale aus. Dieser Satz erfasste im Wesentlichen die Bewegungsstärke und wertete dadurch jede Kopfbewegung als Essen; er wurde durch 14 Merkmale ersetzt, die zusätzlich den Kaurhythmus einbeziehen. Für Stufe 2 verschlechterte dasselbe Verfahren die Genauigkeit, da alle drei Klassen Kaubewegungen sind und viele Merkmale überlappende Information tragen. Verwendet wurde daher eine gruppenbewusste Permutation Importance, bei der die Werte eines Merkmals zufällig durchmischt werden und gemessen wird, wie stark die Genauigkeit fällt. Dass die Aufnahmen als Gruppen behandelt werden, sorgt dafür, dass die Bewertung die Generalisierung über Aufnahmen hinweg abbildet. Von den 52 Merkmalen leisten 39 einen positiven Beitrag (Abbildung 4); die entfernten sind überwiegend absolute Lage- und Orientierungswerte, die nicht das Kauen, sondern die zufällige Kopfhaltung während einer Aufnahme beschreiben.




Abbildung 4: Gruppenbewusste Permutation Importance aller 52 Merkmale für Stufe 2. Grün: behalten, rot: entfernt.

3.4 Modellarchitektur und Evaluationsdesign

Anstelle eines flachen Klassifikators wurde das Problem in zwei Teilprobleme zerlegt. Stufe 1 beantwortet die binäre Frage nach Stillsitzen oder Essen, Stufe 2 klassifiziert nur bei erkannter Essaktivität das konkrete Lebensmittel. Diese Zerlegung trennt das leichte binäre vom schweren Mehrklassenproblem, erlaubt es, die generischen Essen-Aufnahmen gezielt dort einzusetzen, wo sie nützen, und ermöglicht beiden Stufen eine unterschiedliche Vorverarbeitung. Als Modelle kommen ein Random Forest (Breiman, 2001) für Stufe 1 und eine Support Vector Machine mit RBF-Kern (Cortes and Vapnik, 1995) für Stufe 2 zum Einsatz; alle Modelle wurden mit scikit-learn umgesetzt (Pedregosa et al., 2011). Damit Grenzfälle nicht fälschlich in die Lebensmittelklassifikation gelangen, gibt Stufe 1 ein Fenster erst ab einer Mindestkonfidenz weiter. Abbildung 5 zeigt den Ablauf.




Abbildung 5: Finale Pipeline vom Rohsignal über die Merkmalsextraktion zum hierarchischen Zwei-Stufen-Klassifikator.

Ein methodischer Schwerpunkt lag auf der Frage, welche Evaluationsstrategie ein ehrliches Bild liefert. Bei fensterbasierten Daten liegt eine Falle in der klassischen Leave-One-Out-Kreuzvalidierung pro Fenster: Fenster derselben Aufnahme sind einander sehr ähnlich, sodass das Modell de facto auf Nachbarfenstern des Testfensters trainiert und die gemessene Genauigkeit die reale Leistung systematisch überschätzt (Saeb et al., 2017, S. 3). Als ehrliche Metrik wurde deshalb durchgängig Leave-One-Session-Out verwendet, bei dem alle Fenster einer Aufnahme gemeinsam als Testmenge ausgehalten werden. Das entspricht der in der Aktivitätserkennung gebräuchlichen Leave-one-run-out-Strategie, mit der personenspezifische Systeme bewertet werden, während Leave-one-person-out die Generalisierung auf unbekannte Nutzer prüft (Bulling et al., 2014, S. 33:17). Alle berichteten Werte beziehen sich auf die ausgelieferte Konfiguration: Stufe 1 ist ein Random Forest mit 200 Bäumen auf 14 Merkmalen, arbeitet auf bewegungsbereinigten Fenstern und stuft eine Vorhersage unterhalb einer Konfidenz von 0,75 auf Still zurück; Stufe 2 ist eine Support Vector Machine ohne Movement Exclusion. Die Merkmalsauswahl der Stufe 2 wird innerhalb jeder Falte neu bestimmt, sodass die Werte frei von Selektionsbias sind.

4 Ergebnisse

4.1 Klassifikationsleistung

Stufe 1 unterscheidet Stillsitzen und Essen mit einer Genauigkeit von 94,7% bei einer balancierten Genauigkeit von 94,5%, gegenüber einer Mehrheitsbaseline von 76,6%. Stufe 2 erreicht über die drei Lebensmittel 88,7% pro Fenster, mit klassenweisen F1-Werten von 0,87 für Apfel, 0,84 für Kaugummi und 0,94 für Skyr. Auf Mahlzeitebene, wo jedes Fenster einer Mahlzeit abstimmt und das Mehrheitslabel gewinnt, steigt die Genauigkeit

auf 95,0 %, also 76 korrekt zugeordnete von 80 Mahlzeiten. Verkettet man beide Stufen, liegt die Genauigkeit bei 87,5 % pro Fenster, bezogen auf 1319 Fenster, da die 203 Fenster der generischen Sammelklasse keiner Zielklasse zugeordnet werden können, und ebenfalls bei 95,0 % pro Mahlzeit; Stufe 1 verliert auf Mahlzeitebene demnach nichts. Abbildung 6 zeigt die zugehörigen Konfusionsmatrizen.




Abbildung 6: Konfusionsmatrizen der Stufe 2 unter LOSO: links pro Zehn-Sekunden-Fenster, rechts pro Mahlzeit nach Mehrheitsabstimmung.

Die drei Werte messen dieselbe Modellleistung unter verschiedenen Bedingungen (Abbildung 7). Der Wert innerhalb der Aufnahmen von 93,8 % überschätzt, weil das Modell benachbarte Fenster derselben Aufnahme kennt; der LOSO-Wert von 88,7% beschreibt die Übertragung auf eine unbekannte Aufnahme; die Aggregation pro Mahlzeit mit 95,0 % entspricht der Situation im tatsächlichen Einsatz, in dem nicht einzelne Fenster, sondern das Ergebnis einer Mahlzeit zählt. Angesichts des kleinen Datensatzes ist auch der LOSO-Wert vorsichtig zu interpretieren, da er die Generalisierung auf neue Aufnahmen derselben Person beschreibt und nicht auf neue Personen. Der Wert pro Mahlzeit beruht zudem auf nur 80 Mahlzeiten, sodass eine einzelne Fehlzurordnung ihn um mehr als einen Prozentpunkt verschiebt.




Abbildung 7: Dreistufige Bewertung: innerhalb der Aufnahmen (optimistisch), sessionübergreifend (realistisch) und pro Mahlzeit (Systemleistung).

4.2 Fehleranalyse und Klassendesign

Die Fehleranalyse auf einem früheren Datenstand zeigte, dass sich fast alle Fehler auf eine wechselseitige Verwechslung von Apfel und der generischen Klasse konzentrierten. Zwei Ursachen wurden identifiziert. Erstens überlappen die realen Mahlzeiten der Sammelklasse im Merkmalsraum mit den spezifischen Lebensmitteln; ein Experiment mit einer Rückweisungsoption bestätigte dies, da die generischen Aufnahmen mit hoher Konfidenz falsch klassifiziert werden. Es handelt sich also um ein Taxonomieproblem und nicht um ein Konfidenzproblem, das ein Schwellwert lösen könnte. Zweitens entfernte die Movement Exclusion die Crunch-Spitzen des Apfels; ohne sie stieg der Apfel-Recall auf dem damaligen Datenstand von 62 % auf 78 %. Beide Befunde führten zur finalen Architekturentscheidung, die generische Klasse aus Stufe 2 zu entfernen und ausschließlich in Stufe 1 zu belassen. Allein diese Umstellung hob die Apfel-Präzision von 0,53 auf 0,76. Den größten Genauigkeitsgewinn brachte damit das Klassendesign, nicht die Wahl des Modells.

Auf dem finalen Datensatz wurden zwei Stellschrauben gegeneinander geprüft. Die Movement Exclusion macht in Stufe 2 kaum einen Unterschied, was die Entscheidung stützt, sie dort abzuschalten. Die einmalig auf allen Daten bestimmte Merkmalsauswahl liefert dagegen scheinbar bessere Werte als die faltweise bestimmte, nämlich 89,8 statt 88,7 % pro Fenster und 98,8 statt 95,0 % pro Mahlzeit. Der Selektionsbias schlägt damit fast ausschließlich auf die aggregierte Zahl durch, weshalb durchgängig die faltweisen Werte berichtet werden.

Die Fehlerstruktur hat sich gegenüber den früheren Datenständen umgekehrt. Apfel wird nicht mehr übersehen, sondern zu häufig vorhergesagt: Der Recall liegt bei 0,91, die Präzision jedoch nur bei 0,83, weil zusätzlich 47 Kaugummi- und 12 Skyr-Fenster in der Apfel-Spalte landen. Die Abschaltung der Movement Exclusion hat das Recall-Problem des Apfels also behoben und dabei ein Präzisionsproblem erzeugt, das vor allem zulasten des Kaugummis geht. Skyr ist mit einem F1-Wert von 0,94 die am besten trennbare Klasse; da alle drei Klassen annähernd gleich viele Fenster umfassen, liegt das nicht an einem Datenübergewicht. Von den 109 falsch zugeordneten Fenstern entfallen 71 auf die Verwechslung von Apfel und Kaugummi. Skyr unterscheidet sich im Signal also deutlich von beiden, was physikalisch naheliegt, da es gelöffelt und kaum gekaut wird, während Apfel und Kaugummi echte Kaubewegungen erzeugen.

4.3 Modellvergleich und Vergleich mit Deep Learning

Zur Auswahl des Stufe-2-Modells wurden Random Forest, SVM, k-Nearest-Neighbors und ein Multi-Layer Perceptron unter identischen Bedingungen auf 25-Sekunden-Fenstern verglichen. Das Ergebnis fiel eng aus: Alle Modelle lagen innerhalb weniger Prozentpunkte, die SVM erzielte mit 94,1 % das beste Ergebnis, knapp vor dem MLP mit 94,0 % und Random Forest sowie kNN mit je 93 %. Dieser Vergleich wurde auf einem früheren Datenstand von 78 Aufnahmen und mit der optimistischen fensterweisen Metrik durchgeführt und später nicht wiederholt; die absoluten Werte sind daher als

Zwischenstand zu lesen, der Vergleich der Modelle untereinander bleibt jedoch gültig.

Um zu prüfen, ob ein Deep-Learning-Modell bessere Merkmale lernen könnte als die handgefertigten, wurde ein 1D-Convolutional-Neural-Network direkt auf den rohen Zehn-Sekunden-Fenstern mit sieben Kanälen trainiert, ergänzt um Datenaugmentierung. Für einen fairen Vergleich wurden CNN und merkmalsbasierte SVM auf exakt denselben sessionbasierten Splits evaluiert. Ohne Augmentierung erreichte das CNN 67,8 %, mit Augmentierung 73,7 % und liegt damit 1,2 Prozentpunkte über der SVM mit 72,5 %. Ob dieser Unterschied belastbar ist, lässt sich anhand der vorliegenden Daten nicht entscheiden, da keine Signifikanzprüfung durchgeführt wurde; ein Vorteil des CNN lässt sich daraus jedenfalls nicht ableiten. Alle drei Werte liegen unter den oben berichteten Ergebnissen, weil dieser Vergleich noch auf dem Vier-Klassen-Problem einschließlich der generischen Klasse beruht. Festhalten lässt sich damit, dass die handgefertigten Merkmale den gelernten Repräsentationen hier nicht unterlegen sind, obwohl das CNN deutlich mehr Rechenaufwand erfordert. Naheliegend, wenn auch im Rahmen dieses Projekts nicht geprüft, ist die Vermutung, dass eher die Vielfalt der Daten als die Modellkapazität den begrenzenden Faktor darstellt.

4.4 Live-Anwendung

Die Funktionsfähigkeit des Gesamtsystems wird durch eine Live-Webanwendung demonstriert. Die AirPods streamen ihre Sensordaten per HTTP an einen lokalen Python-Server, der sie in einen Ringpuffer von 20 Sekunden schreibt und daraus jeweils die letzten zehn Sekunden als Klassifikationsfenster entnimmt. Alle zwei Sekunden wird klassifiziert und das Ergebnis an ein Browser-Dashboard übertragen (Abbildung 8).




Abbildung 8: Live-Ansicht der Anwendung in zwei Zuständen. Links wird während des Kaugummikauens in Stufe 2 klassifiziert, rechts erkennt bereits Stufe 1 Stillsitzen, sodass keine Lebensmittelklassifikation erfolgt.

Kernstück der Alltagstauglichkeit ist die zeitliche Aggregation pro Mahlzeit. Wann eine Mahlzeit läuft, entscheidet ein einfacher Zustandsautomat: Fünf aufeinanderfolgende Fenster mit der Vorhersage Essen eröffnen eine Mahlzeit, drei aufeinanderfolgende Still-Fenster beenden sie. Diese Hysterese verhindert, dass einzelne Fehlklassifikationen

eine Mahlzeit auslösen oder abbrechen. Nur die Fenster innerhalb einer laufenden Mahlzeit geben eine Stimme ab. Abbildung 9 zeigt beides im Betrieb.




Abbildung 9: Links der Klassifikationsverlauf, in dem alle zwei Sekunden ein Fenster ausgewertet wird; die Tabelle zeigt je Fenster das Magnitudensignal, die Konfidenz und die Stufe, in der die Entscheidung fiel. Rechts die Detailansicht einer abgeschlossenen Mahlzeit: Über 62 Sekunden wurden 28 Fenster klassifiziert, davon 26 als Kaugummi, woraus sich das Mehrheitslabel mit 93 % der Stimmen ergibt.

Der Livebetrieb macht zwei Dinge sichtbar, die in den aggregierten Kennzahlen untergehen. Erstens schwanken die Konfidenzen benachbarter Fenster derselben Mahlzeit erheblich, im gezeigten Beispiel zwischen 82 und 99%; einzelne Fenster sind also spürbar weniger verlässlich als das Mehrheitslabel, was den Gewinn der Abstimmung anschaulich macht. Zweitens traten Fehlklassifikationen einzelner Fenster tatsächlich auf, führten wegen der Hysterese aber weder zu einem Fehlstart noch zu einem vorzeitigen Ende der Mahlzeit. Aus dem Livetest stammt auch eine Korrektur am Modell: Die Konfidenzschwelle der Stufe 1 wurde von 0,95 auf 0,75 abgesenkt, weil Apfelessen die strengere Schwelle häufig nicht passierte und dadurch als Stillsitzen gewertet wurde. Ergänzend zeigt die Anwendung bei abbrechendem Datenstrom einen expliziten Hinweis an, statt still das letzte Fenster zu wiederholen.

Alle validierten Erkenntnisse der Modellierungsphase wurden übernommen, sodass sich die oben berichteten Zahlen genau auf diese Konfiguration beziehen. Ein Unterschied bleibt: Die Anwendung bestimmt die Merkmalsauswahl beim Start einmalig auf allen verfügbaren Daten, während die Auswertung sie in jeder Falte neu berechnet.

5 Fazit und Ausblick

Die Forschungsfrage lässt sich für die untersuchte Einzelperson positiv beantworten: Kaubewegungen, die über die IMU-Sensoren von AirPods Pro erfasst werden, erlauben sowohl die Unterscheidung von Essen und Nicht-Essen als auch die Zuordnung zu einem

von drei bewusst sehr unterschiedlichen Lebensmitteln. Mit 88,7 % sessionübergreifender Genauigkeit pro Fenster und 95,0 % pro Mahlzeit erreicht das System eine Leistung, die ein passives Ernährungstracking auf unveränderter Consumer-Hardware zumindest als machbar erscheinen lässt.

Rückblickend waren drei Entscheidungen ausschlaggebend, von denen keine die Wahl eines besseren Modells betraf. Erstens die sessionübergreifende Evaluation, deren Einführung aufdeckte, wie stark aufnahmespezifische Effekte die Ergebnisse verzerren, und die die Arbeit auf die tatsächlichen Schwachstellen lenkte. Zweitens das Feature Engineering in Kombination mit dem Entfernen sessionspezifischer Merkmale: Das wichtigste Einzelmerkmal ist mit dem Jerk ein neu entwickeltes, und vier der sieben wichtigsten stammen aus der Kaudynamik-Gruppe; das Aussortieren jener Merkmale, die vor allem die Kopfhaltung kodieren, hob die sessionübergreifende Genauigkeit von 87,2 auf 88,7 %. Drittens die Zerlegung in zwei Stufen samt dem daraus folgenden Klassendesign, die es erlaubt, beide Stufen unterschiedlich zu behandeln; ein flaches Modell könnte die Movement Exclusion nicht gleichzeitig nutzen und abschalten. Bemerkenswert ist schließlich, dass sich die aus der Literatur abgeleitete Erwartung nicht bestätigte: Nicht der harte Apfel, sondern das weiche Skyr erwies sich als die am besten trennbare Klasse. Eine mögliche Erklärung ist, dass Skyr gelöffelt wird und sich dadurch deutlich von den beiden gekauten Klassen abhebt; das bleibt allerdings eine Hypothese.

Die zentrale Limitation bleibt die Datenbasis, da sämtliche 103 Aufnahmen von einer Person stammen. Alle Kennzahlen beschreiben daher die Generalisierung auf neue Aufnahmen derselben Person; ob das Modell auf andere Personen mit anderer Anatomie und anderen Kaugewohnheiten übertragbar ist, konnte nicht geprüft werden. Hinzu kommt, dass die Merkmalsauswahl nicht stabil ist, da je nach Trainingsdaten zwischen 14 und 48 der 52 Merkmale gewählt werden, was auf eine begrenzte Robustheit des Verfahrens bei dieser Datenmenge hindeutet. Die Einzelarbeit wirkte sich vor allem auf die Datenerhebung aus, und erschwerend kam hinzu, dass sich mit jeder Erweiterung des Datensatzes sämtliche Kennzahlen verschoben, sodass laufend festzuhalten war, welches Ergebnis auf welchem Datenstand entstanden ist.

Der nächstliegende Schritt ist daher eine Erhebung mit fünf bis zehn Probanden, evaluiert mit Leave-One-Subject-Out. Zu erwarten wäre, dass die Genauigkeit zunächst spürbar sinkt, da Kiefergeometrie, Sitz der AirPods und Kaugewohnheiten variieren. Aufschlussreich wäre vor allem, welche Merkmale diesen Wechsel überstehen; die Vermutung liegt nahe, dass rhythmusbasierte Größen stabiler bleiben als amplitudenabhängige, weil sie beschreiben, wie gekaut wird, und nicht wie stark. Sollte sich das bestätigen, wäre eine personenspezifische Kalibrierung über eine kurze Referenzaufnahme eine naheliegende Erweiterung. Auf Systemebene wäre die Schätzung der Kauanzahl pro Mahlzeit reizvoll, wie sie IMChew verfolgt, da sich daraus eine Gesundheitsmetrik ableiten ließe; die nötigen Bausteine sind in der Pipeline bereits vorhanden. Perspektivisch könnte ein solcher Ansatz an Bedeutung gewinnen, wenn Geräte am Kopf weiter verbreitet sind. Für Anwendungen zum Ernährungstracking

läge der Gewinn vor allem in der Bedienung: Statt dass Nutzer jede Mahlzeit von sich aus eintragen, könnte die Anwendung bei erkannter Essaktivität nachfragen und ein Lebensmittel vorschlagen. Der Grundgedanke ist nicht neu, denn Bell et al. (2020) nennen zwei Studien, in denen das Gerät bei erkannter Essbewegung unmittelbar nachfragt (Bell et al., 2020, S. 9); neu wäre der Vorschlag des konkreten Lebensmittels, der die Eingabe auf eine Bestätigung reduziert. Sämtliche genannten Punkte sind Vorschläge und wurden im Rahmen dieses Projekts nicht überprüft.

Literaturverzeichnis

- Bedri, A., Li, R., Haynes, M., Kosaraju, R. P., Grover, I., Prioleau, T., Beh, M. Y., Goel, M., Starner, T., and Abowd, G. (2017). EarBit: Using wearable sensors to detect eating episodes in unconstrained environments. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 1(3):1–20.
- Bell, B. M., Alam, R., Alshurafa, N., Thomaz, E., Mondol, A. S., de la Haye, K., Stankovic, J. A., Lach, J., and Spruijt-Metz, D. (2020). Automatic, wearable-based, in-field eating detection approaches for public health research: a scoping review. *npj Digital Medicine*, 3(38).
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Bulling, A., Blanke, U., and Schiele, B. (2014). A tutorial on human activity recognition using body-worn inertial sensors. *ACM Computing Surveys*, 46(3):1–33.
- Butterworth, S. (1930). On the theory of filter amplifiers. *Experimental Wireless & the Wireless Engineer*, 7:536–541.
- Choi, T. H. (o.J.). One-page unit reference. Sensor Logger Documentation. <https://github.com/tszheichoi/awesome-sensor-logger/blob/main/UNIT5.md>, abgerufen am 13.09.2026.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20:273–297.
- Guyon, I., Weston, J., Barnhill, S., and Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. *Machine Learning*, 46:389–422.
- Hummel, J., Burzer, M., Schlotter, F., Küttner, M., King, T., Yang, Q., Mascolo, C., Beigl, M., and Röddiger, T. (2026). CHOMP: Multimodal chewing side detection with earphones. *arXiv*. arXiv:2602.02233.
- Ketmalasiri, T., Wu, Y. Y., Butkow, K.-J., Mascolo, C., and Liu, Y. (2024). IMChew: Chewing analysis using earphone inertial measurement units. In *Proceedings of BodySys '24*, pages 29–34, Tokio.

- Papapanagiotou, V., Diou, C., van den Boer, J., Mars, M., and Delopoulos, A. (2021). Recognition of food-texture attributes using an in-ear microphone. *arXiv*. arXiv:2105.09621.
- Pearson, R. K., Neuvo, Y., Astola, J., and Gabbouj, M. (2016). Generalized hampel filters. *EURASIP Journal on Advances in Signal Processing*, 2016(87).
- Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6(5):1–9.

Anhang

Repository. Der vollständige Code, sämtliche Rohaufnahmen, die Notebooks und die Live-Anwendung liegen unter <https://github.com/karstensjonah-design/ML4CS-group-ChewML>. Die Struktur umfasst `data/raw/` mit einem ZIP-Archiv pro Aufnahme, `notebooks/` mit 14 Analyse- und Experimentier-Notebooks (02–15), `ml_httpstreaming/` mit der Live-Anwendung, `reports/` mit den wöchentlichen Projektberichten, den Abbildungen und dem Quelltext dieses Papers sowie `sources/` mit der verwendeten Literatur.

Beiträge der Teammitglieder. Das Projekt wurde nach einem Gruppenwechsel in der fünften Semesterwoche als Einzelarbeit durchgeführt. Datenerhebung, Vorverarbeitung, Merkmalsentwicklung, Modellierung, Evaluation, Live-Anwendung sowie sämtliche Berichte, Präsentationen und dieses Paper stammen vollständig von Jonah Karstens.

Verwendete Werkzeuge. Modelle, Kreuzvalidierung und Merkmalsselektion wurden mit `scikit-learn` umgesetzt (Pedregosa et al., 2011), Signalverarbeitung und Merkmalsberechnung mit `NumPy`, `pandas` und `SciPy`, das 1D-CNN mit `PyTorch`. Die vollständige Liste mit Versionsangaben steht in der Datei `requirements.txt` im Repository. Für Code und Auswertung wurden KI-gestützte Werkzeuge eingesetzt.